

Projet 2 Données Bourgogne-Franche-Comté

Clara Gambardello

2024-12-09

Introduction

Dans le cadre d'un projet portant sur l'analyse de données, nous allons travailler sur une base de données incluse dans R et nommée par `rp2012`. Elle contient les résultats de recensement des villes françaises de plus de 2000 habitants sur différentes variables tel que catégories socio-professionnelles, classes d'âges et logements, le tout disponible en dénombrement et en proportion. Étant libre quant aux axes selon lesquels nous souhaitons analyser ces données nous nous proposons dans un premier temps de chercher des tendances de divergences entre les deux régions avec une analyse en composantes principales, puis nous étudierons plus précisément certaines variables selon les résultats de cette première ACP, enfin à l'aide de méthodes de clustering nous essaierons de décrire les groupes de communes des deux régions selon leurs similitudes. Afin de pouvoir mener nos recherches à bien nous nous devons d'installer et de charger différents packages de R, `ggplot2`, `plotly` et `patchwork` pour les graphiques, `dplyr` pour manipuler nos dataframes ou encore `FactoMineR` et `factoextra` pour les visualisations de nos outils statistiques.

Tout d'abord, nous réalisons un premier tableau pour connaître la population totale du recensement de chaque région.

```
## # A tibble: 2 x 2
##   region      population_totale
##   <chr>          <int>
## 1 Bourgogne      854038
## 2 Franche-Comté  582200
```

La Bourgogne ayant beaucoup plus d'habitants que la Franche-Comté, nous décidons de ne travailler qu'avec les données en proportion afin de ne pas être biaisées par la taille des populations.

Etudes des classes d'âge

Nous commençons par trier notre table de données pour conserver les communes de Bourgogne et de Franche-Comté, cette nouvelle table de données constituera la base de notre travail.

```
donnee <- rp2012

donnee_B_FC <- donnee %>%
  filter(region=="Bourgogne" | region=="Franche-Comté")
```

Nous obtenons une table de 195 individus et de 60 colonnes. Dans un premier temps nous décidons de manière arbitraire de choisir quelques variables qui nous paraissent importantes pour en faire une ACP et en dégager une différence générale entre nos deux régions. Nous décidons de conserver les variables de classes

d'âges, de diplôme du supérieur, de logement hlm, de propriétaire de chomage et d'agriculteur. Après une première tentative qui a donné des graphes peu lisibles, les villes de Dijon et Besançon étant trop excentrés. Nous faisons une nouvelles ACP en ôtant de notre base de données ces deux villes.

```
#Démographie, chomage, immobilier, éducation ACP

donnee_acp_BFC <- donnee_B_FC %>%
  filter(commune!="Dijon" & commune!="Besançon") %>%
  select(commune, region, chom, maison, proprio, age_0_14, age_15_29, age_75p, dipl_sup, hlm, agric)

diag(var(donnee_acp_BFC%>% select(-region, -commune)))
```

```
##      chom      maison      proprio      age_0_14      age_15_29      age_75p      dipl_sup
## 21.628311 382.897845 172.916466   6.286410   8.375749  12.412992  15.139602
##      hlm      agric
## 106.283611   1.453769
```

On constate ici que les variances sont très différentes, on choisit de faire une acp centrée réduite dont la formule de ces variables est la suivante :

$Z_j = \frac{X_j - \bar{X}_j}{\sigma_j} \sqrt{n}$ ou $\sigma_j = \sqrt{Var(X_j)}$ les composantes principale sont donnée par : $Y_j = Za_j$ ou a_j , $j = 1, \dots, n$ sont les vecteurs propres de $Var(Z) = Corr(X)$.

```
acp<-PCA(donnee_acp_BFC %>% select(-region, -commune), graph=FALSE)


acp$eig
```

```
##      eigenvalue percentage of variance cumulative percentage of variance
## comp 1 3.71155122                41.2394580                41.23946
## comp 2 1.91991311                21.3323679                62.57183
## comp 3 1.17113802                13.0126447                75.58447
## comp 4 0.95046892                10.5607658                86.14524
## comp 5 0.56520393                6.2800436                92.42528
## comp 6 0.25729977                2.8588863                95.28417
## comp 7 0.22050591                2.4500657                97.73423
## comp 8 0.13991984                1.5546649                99.28890
## comp 9 0.06399929                0.7111032                100.00000
```

```
indiv<-fviz_pca_ind(acp,
  col.ind=donnee_acp_BFC$region,
  palette=c("darkorchid", "cyan4"),
  legend.title="Région",
  select.ind=list(cos2=0.6))

var<-fviz_pca_var(acp, col.var="cos2")

indiv+var
```



On constate que l'on doit garder 3 composantes principales pour arriver à une variance cumulée de plus de 75%, à l'aide de la commande `select.ind` on ne conserve que les individus bien représentés. En ce qui concerne les variables on constate que les variables “proprio”, “maison”, “hlm”, “chomage” sont bien représentés en dimension 1 on effet leur `cos2` est élevé, en dimension 2 ce sont les variables “age_0_14” et “age_75p” qui sont bien représentés, enfin sur le plan factoriel 1-2 nous avons “age_15_29” qui est bien représenté.

On peut ainsi dire que l'axe 1 oppose les communes avec beaucoup de propriétaires et de maisons aux communes qui contiennent plus d'hlm et d'habitants au chômage. De la même manière, l'axe 2 oppose les communes avec beaucoup d'habitants de plus de 75 ans aux communes qui au contraire ont beaucoup d'habitants entre 0 et 14 ans. Sur cette ACP nous constatons seulement une légère tendance des individus de la Bourgogne vers une population plus âgé que l'individu moyen et au contraire une tendance vers une population plus jeune en Franche-Comté.

Afin de préciser l'impression de divergence des deux régions sur l'âge de la population nous nous aidons d'une AFC, nous ajoutons une variable qualitative sur une colonne qui à chaque commune donne sa classe d'âge dominante.

L'Analyse Factorielle des Correspondances est une méthode statistique qui permet d'étudier les relations entre deux variables qualitatives. Elle permet de représenter graphiquement les modalités de ces variables sous forme de nuages de points, révélant ainsi leurs proximités et leurs oppositions. L'AFC est particulièrement utile pour explorer et visualiser des données issues de tableaux de contingence. Elle permet d'identifier les associations les plus significatives entre ses lignes et ses colonnes, offrant ainsi une compréhension approfondie des liens entre les variables étudiées.

```
classes_age_B_FC<-donnee_B_FC %>% select(pop_0_14, pop_15_29, pop_75p)
indices_max_age_B_FC<-apply(classes_age_B_FC, 1, which.max)
```

```

donnee_B_FC<-donnee_B_FC %>%
  mutate(classe_age_dominante=factor(colnames(classes_age_B_FC)[indices_max_age_B_FC]))

```

Nous réalisons ensuite le tableau de contingence entre les deux variables département et classes d'âge dominante. Ce tableau nous permet ensuite de réaliser un test du χ^2 , en effet une AFC n'a un sens que si l'on peut trouver des associations entre les modalités de différentes variables, ainsi si on accepte l'hypothèse nulle alors les deux variables sont indépendantes il n'y a pas de sens à poursuivre.

La statistique utilisée pour ce test est : $\chi^2 = \sum_{i=1}^I \sum_{j=1}^J \frac{(n_{ij} - \frac{n_{i+}n_{+j}}{n})^2}{\frac{n_{i+}n_{+j}}{n}}$

```

tableau_cont_B_FC<-table(donnee_B_FC$departement, donnee_B_FC$classe_age_dominante)
tableau_cont_B_FC

```

```

##
##               pop_0_14 pop_15_29 pop_75p
## Côte-d'Or           10         16         2
## Doubs                29         12         0
## Haute-Saône          11          5         0
## Jura                  7          8         2
## Nièvre                8          2         8
## Saône-et-Loire       22         10         9
## Territoire de Belfort 10          2         0
## Yonne                16          4         2

```

```

chisq.test(tableau_cont_B_FC)

```

```

##
## Pearson's Chi-squared test
##
## data:  tableau_cont_B_FC
## X-squared = 48.929, df = 14, p-value = 9.218e-06

```

la p-value étant très petite on rejette H_0 et on produit notre AFC.

On regarde maintenant ce que chaque axe représente en terme de variance :

```

##      eigenvalue percentage of variance cumulative percentage of variance
## dim 1 0.16762565          66.80549          66.80549
## dim 2 0.08329034          33.19451          100.00000

```

On remarque que la 1er composante principale represente 66,80% de la variance, la deuxieme represente 33,19% de la variance. Nous souhaitons maintenant connaître les lignes bien représentées selon la dimension :

```

##               Dim 1      Dim 2
## Côte-d'Or      0.12640868 0.873591320
## Doubs          0.83817999 0.161820015
## Haute-Saône    0.91290067 0.087099326
## Jura           0.01362550 0.986374503
## Nièvre         0.99643247 0.003567530
## Saône-et-Loire 0.99713173 0.002868274
## Territoire de Belfort 0.34867091 0.651329089
## Yonne          0.02710881 0.972891186

```

En dimension 1 les départements les mieux représentés sont : “Doubs”, “Haute-Saone”, “Nièvre”, “Sône-et-Loire”, tandis qu’en dimension 2 les départements les mieux représentés sont : Cote d’or, Jura, Yonne. Enfin sur le plan 1-2 le territoire de Belfort est bien représenté. On fait de même avec les colonnes :

```
##           Dim 1      Dim 2
## pop_0_14 0.1901839 0.809816082
## pop_15_29 0.2195278 0.780472153
## pop_75p   0.9934699 0.006530076
```

Ici on constate que les colonnes “pop_0_14” et “pop_15_29” sont bien représentées sur l’axe 2 en revanche la colonne “pop_75_p” est bien représentée sur l’axe 1.


Nous pouvons maintenant représenter notre AFC graphiquement avec un biplot :

```
departements_bourgogne <- c("Côte-d'Or", "Nièvre", "Saône-et-Loire", "Yonne")

regions<-ifelse(rownames(tableau_cont_B_FC) %in% departements_bourgogne, "Bourgogne", "Franche-Comté")

couleurs <- c("Bourgogne" = "#A32990", "Franche-Comté" = "#A68999")

fviz_ca_biplot(AFC, col.row=regions, col.col="darkgreen") +
  scale_color_manual(values=couleurs) +
  labs(title="AFC : Départements et Classes d'âge", color = "Région")
```



Nous constatons alors que les départements de Saône et Loire et de la Nièvre, départements de Bourgogne, ont plus d’habitants de plus de 75 ans que les autres région. En revanche la Haute-Saône le Doubs et le

territoire de Belfort, départements de Franch-Comté, ont une population plus jeune, c'est aussi le cas de l'Yonne en Bourgogne. On retrouve ainsi ce que l'on avait pu observé sur notre première ACP, l'âge de la population dans nos deux régions est une variable qui nous permet de les comparer.

Niveau d'éducation des deux régions

Nous souhaitons maintenant nous concentrer sur le niveau d'étude de nos deux régions, nous réalisons donc une nouvelle ACP.

```
donnee_acp_BFC2 <- donnee_B_FC %>%
  filter(commune!="Dijon" & commune!="Besançon") %>%
  select(commune, region, dipl_aucun, dipl_bepc, dipl_capbep, dipl_bac, dipl_bac2, dipl_sup)

diag(var(donnee_acp_BFC2 %>% select(-region, -commune)))
```

```
## dipl_aucun dipl_bepc dipl_capbep dipl_bac dipl_bac2 dipl_sup
## 37.614570 1.396922 12.797347 4.673664 9.627561 15.139602
```

On constate ici que les variances sont très différentes, on choisit de faire une acp centrée réduite.

```
acp<-PCA(donnee_acp_BFC2 %>% select(-region, -commune), graph=FALSE, ncp=2)


acp$eig
```

```
##          eigenvalue percentage of variance cumulative percentage of variance
## comp 1 2.95885801          49.314300          49.31430
## comp 2 1.30572464          21.762077          71.07638
## comp 3 1.03847753          17.307959          88.38434
## comp 4 0.39512884           6.585481          94.96982
## comp 5 0.22490503           3.748417          98.71823
## comp 6 0.07690595           1.281766         100.00000
```

```
indiv2<-fviz_pca_ind(acp,
  col.ind = donnee_acp_BFC2$region,
  palette = c("darkred", "gold3"),
  legend.title = "Région",
  select.ind=list(cos2=0.75))

var2<-fviz_pca_var(acp, col.var = "cos2")

indiv2+var2
```



On constate que l'on doit garder 2 composantes principales pour arriver à une variance cumulée de plus de 71,07%, la première composante principale représente 49,31 % de la variance, et la deuxième 21,76 %, à l'aide de la commande `select.ind` on ne conserve que les individus bien représentés. En ce qui concerne les variables on constate que les variables “dipl_aucun”, “dipl_bac”, “dipl_bac2”, “dipl_sup” sont bien représentées en dimension 1 on effet leur cos2 est élevé, en dimension 2 c'est la variable “dipl_capbep” qui est bien représenté.

On peut ainsi dire que l'axe 1 oppose les communes qui ont beaucoup d'habitants sans diplômes aux communes qui ont un bac ou un diplôme du supérieur. De la même manière, l'axe 2 oppose les communes qui ont plutôt des habitants diplômés d'un cap ou un bep aux communes qui au contraire en ont peu. Sur cette ACP nous constatons seulement une légère tendance des individus de la Franche-Comté vers une population avec plus de diplômes (bac, bac2, sup) et au contraire une tendance vers une population avec moins de diplômes de type bac et supérieur, en revanche les individus de Bourgogne ont tendance à avoir plus de diplômes de type cap, bep que les individus de Franche-Comté.

Divergences générales

Nous décidons de réaliser un clustering de nos individus, en effet si nous parvenons dans les deux régions à former des groupes et à les caractériser nous espérons que ces groupes soient assez différents pour que nous puissions les interpréter. Nous commençons par trier notre table de données, nous préférons écarter Dijon et Besançon de nos données afin que ces villes ne forment pas un groupe à elle seule.

Le clustering est une technique d'apprentissage non supervisé qui permet de regrouper des objets en fonction de leurs similarités. Parmi les méthodes de clustering, on trouve la méthode de Ward et l'algorithme des kmeans que nous avons utilisé.


La méthode de Ward vise à minimiser la variance intra-classe afin de former des groupes les plus homogènes possible. Elle procède de manière ascendante, en fusionnant à chaque étape les deux groupes dont la fusion entraîne la plus faible augmentation de la variance intra-classe. Cette méthode permet d'obtenir une classification hiérarchique, qui peut être représentée sous forme d'arbre de classification (dendrogramme).

L'algorithme des kmeans, quant à lui, part d'un nombre de groupes prédéfini "k" et affecte chaque objet au groupe dont le centre (moyenne) est le plus proche. Les centres sont ensuite recalculés itérativement jusqu'à ce que la répartition des objets dans les groupes ne change plus.

Pour réaliser nos calculs nous utilisons scale afin de centrer et de réduire nos données et nous calculons la distance euclidienne entre les différents individus.

Nous traçons dans un premier temps la courbe de l'inertie intra-classe afin d'avoir une idée du nombre de classe à conserver.


Graphique de l'inertie intra-classes



Nous réalisons ensuite le dendrogramme de nos individus, nous nous attendons au vu du leur nombre important à un graphique peu lisible.

```
plot(hc_B_CR_SD, labels=d_sDijon$commune, main="Clustering des communes avec le critère de Ward (centré)  
rect.hclust(hc_B_CR_SD, k=3, border="blue")
```

Clustering des communes avec le critère de Ward (centrée-réduit)



```
hclust (*, "ward.D2")
```

Nous décidons après avoir vu les courbes d'inertie intra-classes des deux régions de découper nos individus en 3 groupes nous utilisons "cutree" pour les diviser puis nous affichons leur caractéristiques selon leur centre de gravité.

```
decoup_groupe<-cutree(hc_B_CR_SD,k=3)
aggregate(d_B_sansDijon,list(decoup_groupe),mean) # centre de gravite
```


##	Group.1	pop_tot	age_0_14	age_15_29	age_75p	femmes	chom	agric	
##	1	1 4664.667	16.34919	14.35038	10.61554	50.95586	7.452414	0.5326756	
##	2	2 8465.194	16.23181	16.51749	13.33989	52.93249	15.707604	0.8961135	
##	3	3 3563.206	18.36803	14.00261	10.50887	51.26362	10.104635	1.5401342	
##		indep	cadres	interm	empl	ouvr	etud	dipl_aucun	dipl_bepc
##	1	5.582681	18.901692	30.62587	27.17208	16.40227	46.63399	10.34796	5.916249
##	2	5.532422	7.809043	20.91569	31.57376	31.95117	36.78745	22.01554	6.572007
##	3	6.304368	8.588271	23.47288	30.75482	28.90066	36.20705	17.10198	5.629945
##		dipl_capbep	dipl_bac	dipl_bac2	dipl_sup	resid_sec	proprio	locataire	
##	1	25.77956	17.46339	14.719866	15.055728	1.644543	75.27277	22.81310	
##	2	27.88749	13.74669	8.926669	7.025026	3.965405	52.08583	45.76121	
##	3	30.99551	15.41581	11.079658	6.871407	3.123794	73.17264	25.08965	
##		hlm	maison	appart					
##	1	6.840257	76.09925	23.38039					
##	2	23.006258	56.51582	42.53893					
##	3	9.804115	85.65331	13.63756					

Nous souhaitons maintenant représenter les individus sur un graphique, en les entourant et les colorant selon leurs groupes, nous choisis nos centres de cluster selon le découpage effectué par cutree.


```
# centres initiaux de la classification hierarchique
centre_init<-aggregate(scale(d_B_sansDijon),list(decoup_groupe),mean)
km_dep2_B<-kmeans(scale(d_B_sansDijon),centre_init[,2:26])

a<-fviz_cluster(km_dep2_B, data=d_B_sansDijon, palette=c("#2E9FDF", "#00AFBB", "#E7B800"),
  geom="text", ylim=c(-8,8), main="Clustering pour la Bourgogne")

a+geom_hline(yintercept = 0, color="black")+
  geom_vline(xintercept = 0, color="black")
```




```
fviz_pca_var(PCA(d_B_sansDijon, graph=FALSE), select.var = list(cos2=0.7))
```



En regardant le tableau des caractéristiques, le graphe des clusters ainsi que l'ACP des variables, on peut observer que le premier groupe concentre plus de cadres et de professions intermédiaires, de plus le niveau d'éducation est plus élevé, le taux de chômage y est plus bas que dans les autres clusters et les propriétaires et habitants de maison y sont en grande proportion. Le deuxième groupe a une population plus âgée ainsi qu'un taux de chômage plus élevé que dans les autres clusters, les ouvriers et les employés sont prédominants et les logements hlm représentent une plus grande proportion que dans les autres clusters, enfin le troisième groupe a un pourcentage de population jeune plus élevé avec un peu plus d'agriculteur et d'indépendants que dans les autres groupes et moins de logement hlm. On arrive ainsi à structurer les communes de Bourgogne dans 3 différents clusters ce qui reflète les différences socio-économiques au sein de la région.


Nous reproduisons exactement la même chose pour Franche-Comté en omettant Besançon :


Graphique de l'inertie intra-classes



```
##   Group.1  pop_tot age_0_14 age_15_29  age_75p  femmes      chom      agric
## 1      1 11615.050 17.56070 18.76904 11.273619 52.08567 19.730189 0.2270103
## 2      2  2952.407 18.13207 15.47281  9.693763 51.32487  9.324418 0.3568250
## 3      3  4048.184 17.69074 17.75952 10.325512 50.85526 12.651190 0.7180726
##      indep  cadres  interm      empl      ouvr      etud dipl_aucun dipl_bepc
## 1 4.375367  8.380178 19.15712 27.08489 38.70910 41.18605  27.95923  6.230723
## 2 5.663939 14.202186 26.84481 26.58970 24.31588 45.37826  14.38967  5.468455
## 3 4.865761  8.385274 22.04065 27.90098 35.75405 36.64621  19.11610  6.136763
##      dipl_capbep dipl_bac dipl_bac2  dipl_sup resid_sec  proprio locataire
## 1  23.89052 13.45775  9.296923  7.448648  2.378776 44.41629  53.32053
## 2  27.22185 15.83511 14.431137 11.170856  1.313881 71.15393  27.27866
## 3  28.26191 15.16223 11.391942  7.306397  3.611080 59.18416  38.91084
##      hlm  maison  appart
## 1 28.320625 36.02756 62.98964
## 2  7.998719 75.58991 24.11825
## 3 14.215803 58.97463 40.29262
```

Clustering pour la Franche-Comté





Ici on constate que la Franche-Comté semble se grouper selon la taille de ses villes, le premier groupe est celui des communes les plus peuplées avec un taux de chômage très élevé, une forte proportion d'ouvrier et d'étudiants avec beaucoup de locataires et de logement HLM. Le deuxième groupe avec les communes les moins peuplées a un taux de jeunes plus élevé, une forte proportion de propriétaires et de maisons individuelles et une plus forte proportion de cadres par rapport aux autres clusters. Enfin le troisième groupe a une taille de population intermédiaire avec un certain équilibre entre les tranches d'âges un taux de chômage se situant entre celui des deux autres groupes une proportion presque similaire au groupe 1 d'ouvriers et d'étudiants et un mélange entre appartements et maisons.

On constate ici que les deux régions observent un découpage assez différents de leur communes, on constate notamment des différences significative dans les taux de chômage, de plus la Franche-comté présente une plus grande variations dans ses clusters, la Bourgogne au contraire semble être économiquement plus stable. Cette différence peut s'expliquer selon nos recherches personnelles par la zone frontalière que contient la Franche-Comté, en effet ces zones plus riches favorisent les différences entre les communes.

Conclusion

En conclusion nous avons essayé de mettre en lumière les principales différences des anciennes régions Bourgogne et Franche-Comté, pour cela nous avons utilisé nos outils de statistiques multivariées. Nous avons rencontré plusieurs difficultés lors de ce projet, d'abord parce que en essayant différentes possibilités d'AFC qui pouvaient être intéressantes nous constatons après nos test du χ^2 que nous ne pouvions pas rejeter l'hypothèse nulle, de plus ces deux régions bien que différentes se ressemblent aussi en beaucoup points. Nous voulions également comparer la richesse de ces deux régions mais avons considéré que les variables dont nous disposions ne permettaient pas de se positionner sur ce sujet, en effet bien que nous disposons d'informations sur les professions et logements de chaque commune il est difficile de se positionner sur la

richesse d'une ville seulement selon ces informations. De plus, certaines des variables dont nous disposions avaient un intitulé ambiguë et la documentation ne fournissait pas d'information les concernant, nous les avons donc écartées de notre analyse. Finalement les différences les plus flagrantes sont l'âge des populations, le niveau d'éducation et surtout la stabilité socio-économique et démographique, cette différence pourrait s'expliquer notamment par la zone frontalière présente en Franche-Comté qui n'est pas dotée de la même dynamique que le reste de la région de plus sa relation à l'agriculture, qui est stabilisé en Bourgogne par la production de vins de renommée mondiale, bien que diversifié ne dispose pas d'un produit lui procurant cette même stabilité, enfin la dépendance historique de la Franche-Comté à l'industrie pourrait également être à l'origine de cette instabilité.